CODER HOUSE

Predicción de Incendios en Galicia

Autores:
- Alejandro Nuñez
- Carolina Vinagre
- Claudia Courau
- Francisco Gutiérrez

Tutor:
Jose Ignacio Lopez Saez

Objetivo

En este proyecto realizamos tareas de ***Data Acquisition***, **Data Wrangling** y ***EDA*** que nos guiarán a la obtención de un *modelo de machine learning* fiable predictor de la variable ***causa*** en función de las variables *latitud* y *longitud* geográfica, *temperatura media*, *racha*, *sol*, *trimestre* y *año*.

Con nuestro modelo pretendemos predecir cómo se relacionan las *causas de incendios* con las distintas variables para poder generar planes eficientes de control del fuego: brindar un sistema de soporte de decisión a la planeación estratégica de recursos destinados a incendios forestales

Crear un modelo que ayude en la predicción de desarrollo de incendios a partir de sus *causas* haría mucho más eficiente la distribución de los recursos necesarios para la extinción y ayudaría también en la reducción de costes, daños y pérdidas. Aún teniendo en cuenta la gran dificultad que presenta el desarrollo de un modelo de predicción de incendios (por su complejidad y ser altamente no lineal debido a la incertidumbre asociada al comportamiento humano en relación al fuego), se intentará desarrollar un modelo basándonos en el histórico de datos de la Región de Galicia que es la de mayor afluencia de incendios en España y de la cual tenemos acceso a un dataset con abundantes registros.

DESCRIPCIÓN DE LAS VARIABLES

Latitud y Longitud

geográfica del origen del evento

Racha

Velocidad ráfagas viento (en m/s)

temperatura media (°C)

Sol

Horas de Sol (horas)

Trimestre

Año

MÉTODOS UTILIZADOS

Los valores a predecir (causas de incendio) están predefinidos y se les ha asignado un valor numérico para poder procesar la información:

- Negligencia: 1
- Intencionado: 2
- Causa desconocida: 3
- Rayo: 4
- Fuego reproducido: 5

A continuación mencionaremos los modelos aplicados.

En todos los modelos, se dividió el dataset en dos:

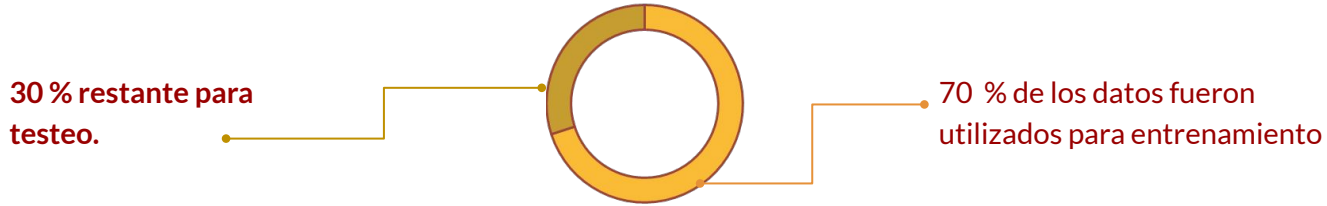

- **Árbol de decisión :** éste modelo tiende a aprender muy bien los datos de entrenamiento pero su performance no es óptima a la hora de generalizar o predecir resultados sobre datos que no vio el árbol.
- **Random Forest:** ensambla varios árboles de decisión por lo que resulta un modelo más robusto para predecir sobre nuevos datos. Obtuvimos una mejora en todas las métricas respecto al anterior modelo mencionado.
- **KNN :** Una desventaja del modelo es la sensibilidad frente a gran cantidad de dimensiones o variables. Definimos realizar un PCA, que es un método para poder “lidiar” con el problema mencionado; se tomaron 19 columnas que explican el 90% de la variabilidad de los datos, y así reducir la cantidad de variables.
- **Catboost:** modelo de regresión basado en potenciación del gradiente. La gran ventaja de este modelo es que no necesitamos transformar las variables categóricas en numéricas para el procesamiento. Además, no tiende a memorizar datos.
- **Máquina de soporte Vectorial :** podríamos encontrarnos con un problema de superposición de clases que no permitiría una óptima separación de clases. Por lo tanto aplicamos el “truco” del kernel para añadir una nueva dimensión y solucionar este problema

Exploratory Data Analysis

Llevamos a cabo una investigación inicial de los datos en búsqueda de patrones y anomalías mediante el cálculo de medidas estadísticas básicas y gráficas simples.

- ➔ Observamos las primeras y últimas 5 filas del dataset para tener un vistazo de los datos
- ➔ Ejecutamos códigos para obtener tamaño y para tipo de dato de cada columna.
- ➔ Buscamos datos nulos.
- ➔ La función "*describe"* nos muestra descriptores estadísticos básicos de nuestras columnas "df.describe().round()"

Hacer un análisis exploratorio de datos nos permite tener una idea de la distribución de variables en su conjunto (forma, sesgo, etc) . Utilizamos histogramas, gráficas de línea y boxplot en búsqueda de:

- ➔ Relaciones entre variables.
- ➔ Valores atípicos o puntos inusuales que puedan indicar problemas de calidad de los datos o conducir a descubrimientos interesantes.
- ➔ Patrones temporales

Data Wrangling

Ejecutamos códigos para ordenamiento y limpieza de nuestra *raw data* con el fin de detectar y eliminar errores de registro.

- ➔ Eliminamos columnas innecesarias.
- ➔ Verificamos que todos los datos cuenten con el mismo formato: Transformamos la columna 'fecha' a tipo numérico para luego dividir mejor las variables

Una vez establecida la variable causa como *variable target* de nuestro proyecto, procedimos a la identificación de las variables más relevantes relacionadas con la primera.

- ➔ Agrupamos dentro del dataset según la variable causa –> df.groupby('causa').size()
- ➔ Mapeamos las variables categoricas que tienen un orden para que sean facilmente adaptables a los modelos.
- ➔ Dado que la variable idmunicipio contiene gran cantidad de posibilidades, que decidimos dropear la columna para no agregar varianza a los datos. Latitud y longitud brindan ya la información de ubicación.
- ➔ Dividimos el dataset en dos (datos categóricos y numéricos) para optimizar su manejo.
- ➔ Utilizamos catboost para entender la importancia de las variables a la hora de predecir la causa. Observamos que a la hora de elegir una variable temporal, nos resulta conveniente inclinarnos por ‘Trimestre’ ya que es mejor predictor por sobre ‘mes’.

Técnicas de Balanceo

```
dataset.groupby('causa').size()

causa
1      534
2    11293
3      830
4      104
5      215
```

Debido al desbalanceo que muestra el dataset, vamos a aplicar técnicas de **“Sampling”:**

- **Oversampling:** consiste en balancear la distribución de las clases añadiendo ejemplos de las clases minoritarias.

  Las técnicas aplicadas fueron:

  - **Random Over Sampling (ROS):**
  - **Synthetic minority over-sampling technique (SMOTE)**

Cabe aclarar que ambos métodos solo fueron aplicados sobre el “train” para no alterar los datos del test (ni su distribución).

- **Undersampling:** de manera inversa a la técnica anterior, elimina muestras de la clase mayoritaria para balancear el dataset. En nuestro caso, se hizo manualmente una submuestra aleatoria de la clase mayoritaria para luego añadirle las clases minoritarias y obtener el dataset a procesar por los diferentes modelos. Como ventaja podemos decir que acorta los tiempos de procesado de datos pero hay una pérdida de información.

Métricas y Conclusiones

Vamos a comenzar describiendo las métricas utilizadas para culminar en los resultados y conclusiones que pudimos obtener:

- Matriz de confusión: en nuestro caso particular el error del modelo a la hora de clasificar tiene el mismo peso relativo (en caso de enfermedades por ejemplo, sería más grave un falso negativo ya que podría no tratarse un caso a tiempo).

  Fue importante realizar cada una de las matrices ya que en un golpe de vista pudimos observar, por ejemplo, que en el modelo "Support Vector Machine" predecía solamente una clase (mayoritaria). Con lo cual, no tendría ningún tipo de valor un modelo de éstas características a pesar de poseer resultados de métricas "aceptables". Además nos permitió ver la posibilidad de aplicar técnicas de balanceo que intentaron paliar esta situación (a pesar de que los resultados no fueron óptimos para este modelo.

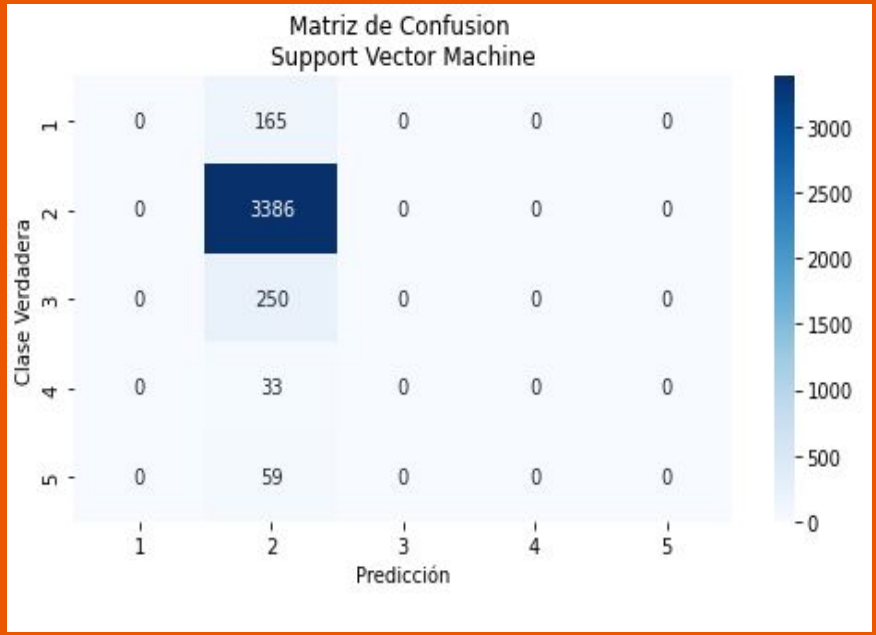

- **Accuracy:** Es el porcentaje total de elementos clasificados correctamente. Es una medida sencilla e intuitiva pero que tiene una gran desventaja: no es buen parámetro para datasets desbalanceados.
-
- **Recall o exhaustividad:** Es el número de elementos identificados correctamente como positivos del total de positivos verdaderos. Buscamos que sea un 100% (independientemente de la métrica precisión) cuando queremos minimizar los falsos negativos.
-
- **Precisión:** Es el número de elementos identificados correctamente como positivo de un total de elementos identificados como positivos. Inversamente a la métrica anterior, buscamos que sea un 100% cuando queremos minimizar los falsos positivos.
-
- **F1-Score:** El valor F1 se utiliza para combinar las medidas de precisión y recall en un sólo valor, a través de la media armónica entre ambos valores. Creemos que es la métrica ideal para nuestro problema ya que, como mencionamos antes, le damos la misma importancia a la precisión y a la exhaustividad.
-
- **ROCAUC: la curva AUC - ROC** es una medida de rendimiento para los problemas de clasificación en varias configuraciones de umbral. ROC es una curva de probabilidad y AUC representa el grado o medida de separabilidad. Indica cuánto es capaz el modelo de distinguir entre clases.Un modelo excelente tiene AUC cerca de 1, lo que significa que tiene una buena medida de separabilidad. Un modelo pobre tiene un AUC cercano a 0, lo que significa que tiene la peor medida de separabilidad.Y cuando AUC es 0.5, significa que el modelo no tiene capacidad de separación de clases.

- **Tiempo:** permite optimizar la elección del modelo al mostrar el costo (o tiempo/recursos) que toma implementar técnicas o modelos más sofisticados frente al beneficio obtenido en mejora de métricas.

Método	Accuracy	Recall	Precision	ROCAUC	F1-Score	Tiempo
Random Forest - Random-Over-Sampling	0.866684	0.866684	0.791670	0.748906	0.814361	51.045010
Random Forest	0.871821	0.871821	0.886013	0.741989	0.813550	3.499104
Random Forest - SMOTE	0.855381	0.855381	0.787795	0.753814	0.813520	65.163999
k-Nearest-Neighbor	0.862831	0.862831	0.789151	0.595602	0.810536	0.002956
Support Vector Machine	0.869766	0.869766	0.886727	0.418798	0.809185	5.872736
Catboost	0.826355	0.826355	0.790591	0.517953	0.806863	12.660552
Arbol de Decision	0.772669	0.772669	0.791550	0.570500	0.781815	0.171534
Catboost - SMOTE	0.703057	0.703057	0.798973	0.724738	0.744262	13.328406
Support Vector Machine - SMOTE	0.666838	0.666838	0.833735	0.501958	0.708688	755.390434
Support Vector Machine - Random-Over-Sampling	0.665810	0.665810	0.834127	0.463237	0.708251	728.200357
Catboost - Random-Over-Sampling	0.499101	0.499101	0.829066	0.744157	0.597705	8.424725
Catboost - Random-Under-Sampling	0.489593	0.489593	0.552612	0.751714	0.504501	6.245008
Random Forest - Random-Under-Sampling	0.556561	0.556561	0.497379	0.732526	0.463363	1.326793
k-Nearest-Neighbor - Random-Under-Sampling	0.507692	0.507692	0.457997	0.632401	0.460659	0.001743
Arbol de decision - Random-Under-Sampling	0.441629	0.441629	0.454825	0.574690	0.447603	0.047004
Support Vector Machine - Random-Under-Sampling	0.524887	0.524887	0.750619	0.473166	0.361346	1.151571

En primer lugar notamos que la técnica ***Random Under Sampling*** fue la que arrojó los peores resultados en métricas. Con lo cual podemos afirmar que eliminar datos para intentar balancear las clases no es recomendable para nuestro problema.

Es importante complementar las distintas métricas y visualizar la matriz de confusión ya que se puede obtener buenas métricas a pesar de que el modelo no sea útil (específicamente nos referimos al caso de la Maquina de Soporte Vectorial que mencionamos en párrafos anteriores).

Random Forest es el modelo que mejor perfoma en la métrica F1 Score; de todas formas notamos que en el caso de aplicación de las técnicas **ROS** (mejor F1 observado) y **SMOTE**, el tiempo requerido es muy alto frente a otros modelos.

Por lo tanto, podríamos elegir entre dos modelos ganadores: KNN y Random Forest. El primero tiene tiempos muy bajos; A pesar de ello, notamos que si bien Random Forest no tiene el valor mínimo de tiempo, tampoco es demasiado costoso. Por lo tanto **Random Forest le saca una leve ventaja en F1** (además de una mayor simpleza a la hora de construirlo) **y termina siendo el modelo elegido**

Mejoras

A partir de la mirada integral que alcanzamos al realizar el proyecto, creemos conveniente implementar a futuro otras técnicas que busquen atacar el problema de desbalanceo presente en los datos.

Sugerencias:

a) se podría enfocar el problema como de clasificación binaria (dejando atrás las 5 clases de la variable target actual) y alcanzar un mejor balanceo en los datos.

b) se podría realizar un approach al estilo divide and conquer, atacando el problema con un stackeo de modelos: el primero predice si la clase es mayoritaria o minoritaria (binario) y, de resultar clase minoritaria, el segundo modelo se encarga de decidir a cual clase pertenece (multiclase balanceada).

c) Además se podría aplicar un Stratified K-Fold Cross-Validation.

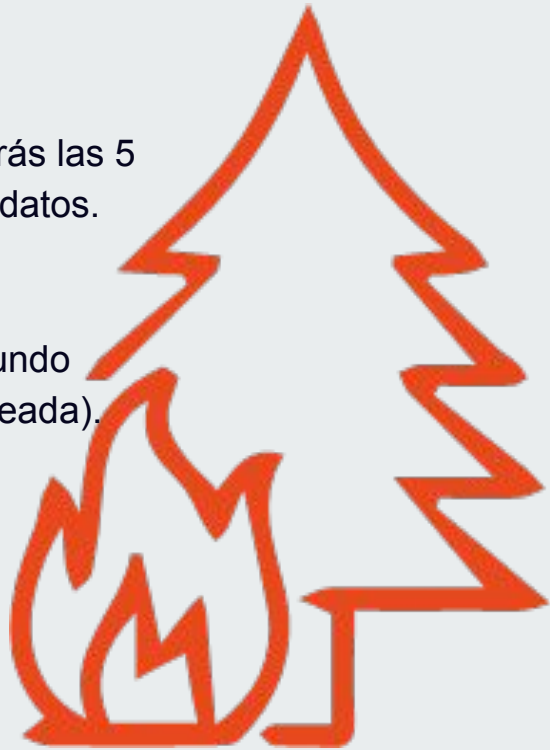

¡MUCHAS GRACIAS!